



UNIVERSIDAD TECNOLÓGICA DE BOLÍVAR

PROGRAMACIÓN PARA CIENCIA DE DATOS – NRC 2479

**CONFLICTO ARMADO EN COLOMBIA Y SUS EFECTOS
TERRITORIALES**

Valentina Julio - T00081186

Javier Mercado - T00071286

Kevin Mendoza - T00100515

Jorge Morales - T00071291

Juan Diego Serpa - T00076352

Revisado por

Prof. Jorge Luis Villalba

Cartagena, Colombia

8 de marzo de 2026

Table of contents

1	Lectura de los datos	2
2	Oportunidades de mejora del dataset	2
3	Materiales y Métodos.	3
4	Descripción de las variables del dataset.	3
5	Cantidad de observaciones por variable y datos faltantes.	4
6	Para las variables cuantitativas: valores mínimo y máximo.	5

1 Lectura de los datos

```
import pandas as pd

df = pd.read_excel("conflicto_y_paz.xlsx")
df
```

	Código Departamento	Departamento	Código Entidad	Entidad	Dimensión	Subcategoría
0	NaN	NaN	NaN	NaN	NaN	NaN
1	1.0	Colombia	1001.0	Colombia	Paz y víctimas	Restitución c
2	5.0	Antioquia	5002.0	Abejorral	Paz y víctimas	Restitución c
3	5.0	Antioquia	5004.0	Abriaquí	Paz y víctimas	Restitución c
4	5.0	Antioquia	5021.0	Alejandro	Paz y víctimas	Restitución c
...	...	...	...	...	...	...
86130	5.0	Antioquia	5021.0	Alejandro	Paz y víctimas	Víctimas
86131	5.0	Antioquia	5004.0	Abriaquí	Paz y víctimas	Víctimas
86132	5.0	Antioquia	5002.0	Abejorral	Paz y víctimas	Víctimas
86133	5.0	Antioquia	5001.0	Medellín	Paz y víctimas	Víctimas
86134	1.0	Colombia	1001.0	Colombia	Paz y víctimas	Víctimas

2 Oportunidades de mejora del dataset

A partir de la revisión inicial del dataset, se identificaron las siguientes oportunidades de mejora relacionadas con la calidad y estructura de los datos:

1. **Presencia de valores faltantes**

Se observan valores nulos (NaN) en algunas columnas como *Código Departamento*, *Departamento* y *Entidad*.

Esto sugiere la necesidad de implementar procesos de limpieza y validación de datos para evitar registros incompletos.

2. **Inconsistencia en los tipos de datos**

Algunos identificadores numéricos aparecen como números decimales (por ejemplo 5.0). so podría estandarizar los tipos de datos para que los códigos territoriales se manejen como enteros o cadenas.

3. **Alta presencia de variables categóricas repetidas**

Columnas como *Dimensión*, *Subcategoría*, *Indicador* y *Fuente* contienen muchos valores repetidos.

Esto podría optimizarse mediante procesos de normalización o tablas de referencia.

4. **Gran volumen de registros**

El dataset contiene más de 80 mil registros, lo cual puede dificultar algunos análisis iniciales o visualizaciones.

Una mejora sería generar agregaciones o subconjuntos de datos por año o por departamento.

5. **Falta de documentación detallada de los indicadores**

Aunque existe información de fuente y unidad de medida, no se incluyen definiciones completas de cada indicador.

Se recomienda incorporar un diccionario de datos o metadatos descriptivos.

6. **Redundancia en la información territorial**

Los departamentos y municipios aparecen repetidos en múltiples registros.

Una posible mejora sería organizar los datos en estructuras relacionales separando territorios, indicadores y registros temporales.

3 **Materiales y Métodos.**

1. **Descripción de obtencion del dataset** el dataset se obtuvo de la plataforma *Terridata* a travez del link <https://terridata.dnp.gov.co/index-app.html#/descargas>

4 **Descripción de las variables del dataset.**

A continuación se presentan las variables principales del dataset y su tipo de dato según su naturaleza estadística.

```

variables = pd.DataFrame({
    "Variable": df.columns,
    "Tipo de dato estadístico": [
        "Discreto",      # Código Departamento
        "Nominal",       # Departamento
        "Discreto",      # Código Entidad
        "Nominal",       # Entidad
        "Nominal",       # Dimensión
        "Nominal",       # Subcategoría
        "Nominal",       # Indicador
        "Continuo",      # Dato Numérico
        "Ordinal",       # Dato Cualitativo
        "Discreto",      # Año
        "Ordinal",       # Mes
        "Nominal",       # Fuente
        "Nominal"        # Unidad de Medida
    ]
})
variables

```

	Variable	Tipo de dato estadístico
0	Código Departamento	Discreto
1	Departamento	Nominal
2	Código Entidad	Discreto
3	Entidad	Nominal
4	Dimensión	Nominal
5	Subcategoría	Nominal
6	Indicador	Nominal
7	Dato Numérico	Continuo
8	Dato Cualitativo	Ordinal
9	Año	Discreto
10	Mes	Ordinal
11	Fuente	Nominal
12	Unidad de Medida	Nominal

5 Cantidad de observaciones por variable y datos faltantes.

```

observaciones = {
    "Obeservaciones": df.count(),
    "Datos_faltantes": df.isnull().sum()
}
df_observaciones = pd.DataFrame(observaciones)
df_observaciones

```

	Obeservaciones	Datos_faltantes
Código Departamento	86134	1
Departamento	86134	1
Código Entidad	86134	1
Entidad	86134	1
Dimensión	86134	1
Subcategoría	86134	1
Indicador	86135	0
Dato Numérico	77144	8991
Dato Cualitativo	7714	78421
Año	86134	1
Mes	86134	1
Fuente	86135	0
Unidad de Medida	86134	1

Este análisis permite identificar cuántos registros tiene cada variable del dataset y cuántos valores faltantes (NA) existen en cada columna. Esto ayuda a evaluar la calidad de los datos y detectar posibles problemas de información incompleta.

6 Para las variables cuantitativas: valores mínimo y máximo.

```

minmax = {
    "Minimo" : df.select_dtypes("number").min(),
    "Maximo" : df.select_dtypes("number").max()
}

df_minmax = pd.DataFrame(minmax)
df_minmax

```

	Minimo	Maximo
Código Departamento	1.0	99.0
Código Entidad	1001.0	99773.0
Año	2002.0	2023.0
Mes	4.0	12.0

En esta sección se calculan los valores mínimo y máximo de las variables numéricas del dataset. Esto permite conocer el rango de los datos y entender los límites de las variables cuantitativas.

```
for col in df.select_dtypes("object").columns:
    print("\nVariable:", col)
    print("Número de categorías:", df[col].nunique())
    print("Categorías más frecuentes:")
    print(df[col].value_counts().head(10))
```

```
Variable: Departamento
Número de categorías: 34
Categorías más frecuentes:
Departamento
Antioquia          9572
Boyacá              9420
Cundinamarca       8890
Santander           6684
Nariño              4936
Tolima              3644
Bolívar             3568
Cauca               3264
Valle del Cauca    3264
Norte de Santander 3112
Name: count, dtype: int64
```

```
Variable: Entidad
Número de categorías: 1045
Categorías más frecuentes:
Entidad
La Unión           304
Villanueva         304
Buenavista         304
Nariño              302
Córdoba            302
```

Bolívar 302
 Sucre 302
 Argelia 228
 Granada 228
 Guadalupe 228
 Name: count, dtype: int64

Variable: Dimensión
 Número de categorías: 1
 Categorías más frecuentes:
 Dimensión
 Paz y víctimas 86134
 Name: count, dtype: int64

Variable: Subcategoría
 Número de categorías: 3
 Categorías más frecuentes:
 Subcategoría
 Construcción de Paz 65830
 Víctimas 18160
 Restitución de tierras 2144
 Name: count, dtype: int64

Variable: Indicador
 Número de categorías: 19
 Categorías más frecuentes:
 Indicador
 Hectáreas de cultivo de coca
 Eventos de Minas Antipersonal
 Índice de Incidencia del Conflicto Armado - IICA
 Personas en proceso de reincorporación
 Categoría del Índice de Incidencia del Conflicto Armado - IICA
 Víctimas ubicadas
 Víctimas de Desplazamiento Forzado ubicadas
 Víctimas por ocurrencia
 Proporción de Víctimas de Desplazamiento Forzado que Superan la Situación de Vulnerabilidad
 Proporción de Víctimas de Desplazamiento Forzado que cumplen el derecho a la Educación en com
 Name: count, dtype: int64

Variable: Dato Numérico
 Número de categorías: 5598
 Categorías más frecuentes:
 Dato Numérico

0,00	42356
1,00	2749
2,00	1353
0,01	1178
0,02	815
3,00	813
4,00	572
0,03	529
5,00	402
0,94	392

Name: count, dtype: int64

Variable: Dato Cualitativo

Número de categorías: 7

Categorías más frecuentes:

Dato Cualitativo

Medio Bajo	3256
SI	1102
NO	1102
Bajo	963
Medio	558
Alto	388
Muy Alto	345

Name: count, dtype: int64

Variable: Fuente

Número de categorías: 11

Categorías más frecuentes:

Fuente

Ministerio de Justicia y el Derecho

Dirección para la Acción Integral contra Minas Antipersonal (DAICMA)

Unidad Para la Atención y Reparación Integral a las Víctimas - Subdirección Red Nacional de DNP

Agencia para la Renovación del Territorio - ART

Atención y Reparación Integral a las Víctimas - Subdirección Red Nacional de Información

Agencia de Renovación del Territorio - ART

Centro Nacional de Memoria Histórica

Unidad de Restitución de Tierras

Unidad de Restitución de Tierras

Name: count, dtype: int64

Variable: Unidad de Medida

Número de categorías: 6

Categorías más frecuentes:

Unidad de Medida

Número 39599

Hectáreas 22700

Porcentaje 11350

- 5675

Personas 4540

Hechos 2270

Name: count, dtype: int64

```
C:\Users\juans\AppData\Local\Temp\ipykernel_27236\2273258543.py:1: Pandas4Warning: For backwards compatibility,
See https://pandas.pydata.org/docs/user_guide/migration-3-strings.html#string-
migration-select-dtypes for details on how to write code that works with pandas 2 and 3.
  for col in df.select_dtypes("object").columns:
```

Aquí se identifican las categorías presentes en cada variable cualitativa del dataset. Esto permite conocer los diferentes tipos o clasificaciones que existen dentro de los datos. En esta sección se identifican las categorías presentes en cada variable cualitativa del dataset mediante la obtención de sus valores únicos. Esto permite conocer los diferentes tipos o clasificaciones que aparecen en cada variable y facilita la comprensión de la estructura de los datos.