



Conflicto Armado en Colombia y sus Efectos Territoriales

Análisis Estadístico Descriptivo — Informe Final

Javier Mercado T00071286

Jorge Morales T00071291

Juan Diego Serpa T00076352

Revisado por

Prof. Jorge Luis Villalba

Programación para Ciencia de Datos — NRC 2479

UNIVERSIDAD TECNOLÓGICA DE BOLÍVAR

Escuela de Transformación Digital

Cartagena de Indias, mayo de 2026

Tabla de Contenidos

1	Presentación del Proyecto	3
1.1	Contexto	3
1.2	Objetivo	3
2	Dataset y Variables	4
2.1	Descripción general	4
2.2	Variables del dataset	4
3	Calidad de Datos	5
3.1	Datos faltantes	5
3.2	Valores repetidos por variable	5
4	Estadística Descriptiva	6
4.1	Medidas de tendencia central	6
4.1.1	Media	6
4.1.2	Mediana	6
4.1.3	Moda	6
4.1.4	Rango	6
4.2	Medidas de dispersión	6
4.2.1	Varianza muestral	6
4.2.2	Desviación estándar	6
4.2.3	Coefficiente de variación	6
4.3	Medidas de posición — Cuartiles	7
4.4	Medidas de forma	7
4.4.1	Asimetría (Sesgo de Fisher)	7
4.4.2	Curtosis (excess kurtosis)	7
5	Análisis de Frecuencias — Variables Categóricas	8
6	Visualizaciones	11
6.1	Variables numéricas	11
6.2	Variables categóricas	13
7	Hallazgos del Análisis	17
7.1	Concentración territorial	17
7.2	Homogeneidad temática	17
7.3	Tendencia temporal reciente	17
7.4	Estacionalidad del reporte	17
7.5	Dispersión de entidades reportantes	17
7.6	Calidad de los datos	17
8	Uso de la Librería <code>analizador</code>	18
8.1	Descripción	18
8.2	Arquitectura	18
8.3	Uso en este trabajo	18
8.4	Decisiones de diseño relevantes	18
9	Referencias	20

9.1	Dataset	20
9.2	Estadística descriptiva	20
9.3	Fórmulas específicas	20
9.4	Herramientas	20

1 Presentación del Proyecto

1.1 Contexto

El presente informe corresponde al Trabajo Final del curso **Programación para Ciencia de Datos (NRC 2479)** de la Universidad Tecnológica de Bolívar. El análisis se realizó sobre el dataset *Conflicto y Paz* de la plataforma **Terridata** del Departamento Nacional de Planeación (DNP), disponible en <https://terridata.dnp.gov.co>.

El dataset consolida indicadores territoriales sobre el conflicto armado en Colombia, reportados por múltiples entidades del Estado a lo largo de 21 años (2002–2023).

1.2 Objetivo

Aplicar técnicas de análisis estadístico descriptivo para caracterizar el dataset, identificar patrones territoriales y temporales, y evaluar la calidad de los datos, usando la librería `analizador` desarrollada por el equipo como parte del proyecto.

2 Dataset y Variables

2.1 Descripción general

Métrica	Valor
Total de registros	86,134
Total de variables	13
Variables numéricas	4
Variables categóricas	9
Cobertura temporal 2002 - 2023	

2.2 Variables del dataset

Variable	Tipo	Descripción
Código Departamento	Discreto	Código DANE del departamento
Departamento	Nominal	Nombre del departamento
Código Entidad	Discreto	Código de la entidad reportante
Entidad	Nominal	Nombre de la entidad reportante
Dimensión	Nominal	Dimensión temática del indicador
Subcategoría	Nominal	Subcategoría dentro de la dimensión
Indicador	Nominal	Nombre del indicador medido
Dato Numérico	Continuo	Valor cuantitativo del indicador
Dato Cualitativo	Ordinal	Clasificación cualitativa del indicador
Año	Discreto	Año de registro
Mes	Ordinal	Mes de registro
Fuente	Nominal	Entidad fuente del dato
Unidad de Medida	Nominal	Unidad en que se expresa el indicador

3 Calidad de Datos

3.1 Datos faltantes

Variable	Total registros	Datos faltantes	% Faltante
Código Departamento	86134	0	0.000
Departamento	86134	0	0.000
Código Entidad	86134	0	0.000
Entidad	86134	0	0.000
Dimensión	86134	0	0.000
Subcategoría	86134	0	0.000
Indicador	86134	0	0.000
Dato Numérico	86134	8990	10.437
Dato Cualitativo	86134	78420	91.044
Año	86134	0	0.000
Mes	86134	0	0.000
Fuente	86134	0	0.000
Unidad de Medida	86134	0	0.000

Se identificaron valores faltantes principalmente en variables territoriales. Las variables numéricas (Año, Mes, Código Departamento, Código Entidad) presentan cobertura completa, lo que garantiza la integridad del análisis cuantitativo.

3.2 Valores repetidos por variable

Las variables categóricas presentan alta repetición estructural, esperada dado el modelo de datos longitudinal del dataset: cada indicador se repite por departamento y por año. La variable **Dimensión** tiene un único valor (Paz y víctimas) en los 86,134 registros, lo que confirma que el dataset es temáticamente homogéneo.

4 Estadística Descriptiva

4.1 Medidas de tendencia central

Las siguientes medidas se calcularon manualmente usando la librería `analizador`, sin depender de funciones estadísticas de `pandas` o `numpy`.

4.1.1 Media

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

4.1.2 Mediana

$$Me = \begin{cases} x_{\frac{n+1}{2}} & \text{si } n \text{ es impar} \\ \frac{x_{\frac{n}{2}} + x_{\frac{n}{2}+1}}{2} & \text{si } n \text{ es par} \end{cases}$$

4.1.3 Moda

Valor con mayor frecuencia absoluta en la distribución.

4.1.4 Rango

$$R = x_{max} - x_{min}$$

	Variable	Media	Mediana	Moda(s)	Rango
Código	Departamento	37.6944	25.0	5	98
	Código Entidad	38112.8039	25807.0	1001, 5002, 5004	98772
	Año	2016.0952	2018.0	2023	21
	Mes	11.1947	12.0	12	8

4.2 Medidas de dispersión

4.2.1 Varianza muestral

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

4.2.2 Desviación estándar

$$s = \sqrt{s^2} = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$

4.2.3 Coeficiente de variación

$$CV = \frac{s}{\bar{x}} \times 100$$

	Variable	Varianza	Desv. Estándar	CV (%)	Rango
Código	Departamento	6.784554e+02	26.0472	69.10	98
	Código Entidad	6.770160e+08	26019.5311	68.27	98772
	Año	4.277180e+01	6.5400	0.32	21
	Mes	5.003200e+00	2.2368	19.98	8

4.3 Medidas de posición — Cuartiles

Los cuartiles se calcularon por **interpolación lineal**. Para el cuartil de orden p :

$$L = \frac{p}{100}(n - 1)$$

Sea $i = \lfloor L \rfloor$ y $f = L - i$, entonces:

$$Q_p = x_i + f \cdot (x_{i+1} - x_i)$$

El **rango intercuartílico** mide la dispersión del 50% central:

$$IQR = Q_3 - Q_1$$

Variable	Q1	Q2 (Mediana)	Q3	IQR
Código Departamento	15.0	25.0	66.0	51.0
Código Entidad	15667.0	25807.0	66000.0	50333.0
Año	2011.0	2018.0	2022.0	11.0
Mes	12.0	12.0	12.0	0.0

4.4 Medidas de forma

4.4.1 Asimetría (Sesgo de Fisher)

$$\gamma_1 = \frac{1}{n} \cdot \frac{\sum_{i=1}^n (x_i - \bar{x})^3}{s^3}$$

Valor	Interpretación
$\gamma_1 > 0$	Asimetría positiva (cola derecha)
$\gamma_1 < 0$	Asimetría negativa (cola izquierda)
$\gamma_1 = 0$	Distribución simétrica

4.4.2 Curtosis (excess kurtosis)

$$\gamma_2 = \frac{1}{n} \cdot \frac{\sum_{i=1}^n (x_i - \bar{x})^4}{s^4} - 3$$

Valor	Tipo	Descripción
$\gamma_2 > 0$	Leptocúrtica	Cola más pesada que la normal
$\gamma_2 < 0$	Platicúrtica	Cola más ligera que la normal
$\gamma_2 = 0$	Mesocúrtica	Igual que la distribución normal

Variable	Asimetría	Curtosis	Tipo asimetría	Tipo curtosis
Código Departamento	0.4444	-1.1418	Positiva →	Platicúrtica
Código Entidad	0.4428	-1.1438	Positiva →	Platicúrtica
Año	-0.7356	-0.7848	Negativa ←	Platicúrtica
Mes	-2.4895	4.4170	Negativa ←	Leptocúrtica

5 Análisis de Frecuencias — Variables Categóricas

=====

Variable: Departamento

Moda: Antioquia

	Frecuencia absoluta	Frecuencia relativa (%)	Frecuencia acumulada (%)
Departamento			
Antioquia	9572	11.11	11.11
Boyacá	9420	10.94	22.05
Cundinamarca	8890	10.32	32.37
Santander	6684	7.76	40.13
Nariño	4936	5.73	45.86
Tolima	3644	4.23	50.09
Bolívar	3568	4.14	54.23
Valle del Cauca	3264	3.79	58.02

=====

Variable: Entidad

Moda: Villanueva

	Frecuencia absoluta	Frecuencia relativa (%)	Frecuencia acumulada (%)
Entidad			
Villanueva	304	0.35	0.35
La Unión	304	0.35	0.70
Buenavista	304	0.35	1.05
Bolívar	302	0.35	1.40
Sucre	302	0.35	1.75
Córdoba	302	0.35	2.10
Nariño	302	0.35	2.45
San Francisco	228	0.26	2.71

=====

Variable: Dimensión

Moda: Paz y víctimas

	Frecuencia absoluta	Frecuencia relativa (%)	Frecuencia acumulada (%)
Dimensión			
Paz y víctimas	86134	100.0	100.0

=====

Variable: Subcategoría

Moda: Construcción de Paz

	Frecuencia absoluta	Frecuencia relativa (%)	Frecuencia acumulada (%)
Subcategoría			
Construcción de Paz	65830	76.43	76.43
Víctimas	18160	21.08	97.51
Restitución de tierras	2144	2.49	100.0

=====

Variable: Indicador

Moda: Eventos de Minas Antipersonal

Indicador

Eventos de Minas Antipersonal

Hectáreas de cultivo de coca

Categoría del Índice de Incidencia del Conflicto Armado - IICA

Índice de Incidencia del Conflicto Armado - IICA

Personas en proceso de reincorporación

Proporción de Víctimas de Desplazamiento Forzado que cumplen el derecho a la Educación

Proporción de Víctimas de Desplazamiento Forzado que cumplen el derecho a la Generación de Ingresos

Proporción de Víctimas de Desplazamiento Forzado que cumplen el derecho a la Salud en

Variable: Dato Numérico

Moda: 0,00

	Frecuencia absoluta	Frecuencia relativa (%)	Frecuencia acumulada (%)
Dato Numérico			
0,00	42356	54.91	54.91
1,00	2749	3.56	58.47
2,00	1353	1.75	60.22
0,01	1178	1.53	61.75
0,02	815	1.06	62.81
3,00	813	1.05	63.86
4,00	572	0.74	64.60
0,03	529	0.69	65.29

Variable: Dato Cualitativo

Moda: Medio Bajo

	Frecuencia absoluta	Frecuencia relativa (%)	Frecuencia acumulada
Dato Cualitativo			
Medio Bajo	3256	42.21	42
SI	1102	14.29	56
NO	1102	14.29	70
Bajo	963	12.48	83
Medio	558	7.23	90
Alto	388	5.03	95
Muy Alto	345	4.47	100

Variable: Fuente

Moda: Dirección para la Acción Integral contra Minas Antipersonal (DAICMA)

Fuente

Dirección para la Acción Integral contra Minas Antipersonal (DAICMA)

Ministerio de Justicia y el Derecho

Unidad Para la Atención y Reparación Integral a las Víctimas - Subdirección Red Nacio

DNP

Agencia para la Renovación del Territorio - ART

Atención y Reparación Integral a las Víctimas - Subdirección Red Nacional de Informac

Agencia de Renovación del Territorio - ART

Unidad de Restitución de Tierras

=====

Variable: Unidad de Medida

Moda: Número

	Frecuencia absoluta	Frecuencia relativa (%)	Frecuencia acumulada
Unidad de Medida			
Número	39599	45.97	45
Hectáreas	22700	26.35	72
Porcentaje	11350	13.18	85
-	5675	6.59	92
Personas	4540	5.27	97
Hechos	2270	2.64	100

6 Visualizaciones

6.1 Variables numéricas




Figure 1: Histogramas de variables numéricas




Figure 2: Curvas de densidad KDE




Figure 3: Boxplots de variables numéricas

6.2 Variables categóricas












Figure 4: Top 10 categorías por variable cualitativa







7 Hallazgos del Análisis

7.1 Concentración territorial

Los cinco departamentos con mayor cantidad de registros son **Antioquia** (9,572), **Boyacá** (9,420), **Cundinamarca** (8,890), **Santander** (6,684) y **Nariño** (4,936). Estos departamentos concentran más del 45% de los registros totales, lo que refleja su relevancia histórica como territorios con alta incidencia del conflicto armado y mayor capacidad institucional de reporte.

La distribución del Código Departamento presenta **asimetría positiva** ($\gamma_1 = 0.44$) y **curtosis platicúrtica** ($\gamma_2 = -1.14$), indicando que los registros se distribuyen con mayor peso en departamentos de código bajo (principalmente de la región Andina) y con una dispersión uniforme sin picos pronunciados.

7.2 Homogeneidad temática

El dataset es **temáticamente homogéneo**: la variable Dimensión tiene un único valor (**Paz y víctimas**) en los 86,134 registros. Los indicadores más frecuentes son los **Eventos de Minas Antipersonal** (22,700 registros), las **Hectáreas de cultivo de coca** (22,700) y el **Índice de Incidencia del Conflicto Armado — IICA** (5,675), concentrando entre los tres más del 59% de todos los registros.

7.3 Tendencia temporal reciente

La cobertura temporal abarca 2002–2023, pero la distribución presenta **asimetría negativa** ($\gamma_1 = -0.74$), con concentración en los años recientes. Los años con más registros son 2023 (13,494), 2022 (11,350) y 2018–2020 (5,675 cada uno). Esto es consistente con el fortalecimiento del sistema de monitoreo pos-acuerdo de paz de 2016 y el aumento de la capacidad institucional de reporte territorial.

7.4 Estacionalidad del reporte

La variable Mes presenta la distribución más inusual: **asimetría negativa pronunciada** ($\gamma_1 = -2.49$) y **curtosis leptocúrtica** ($\gamma_2 = 4.42$). Los cuartiles Q1, Q2 y Q3 coinciden todos en el mes 12 (diciembre). Esto confirma que la gran mayoría de los indicadores se reportan con **corte anual a diciembre**, no con seguimiento mensual continuo.

7.5 Dispersión de entidades reportantes

El Código Entidad tiene una media de 38,112 con una desviación estándar de 26,019 y un CV del 68.3%, lo que indica **alta heterogeneidad** en el ecosistema institucional reportante. El rango va de 1,001 a 99,773, abarcando entidades de todos los niveles de gobierno.

7.6 Calidad de los datos

Las variables numéricas (Año, Mes, Código Departamento, Código Entidad) presentan **cobertura completa** (0% de datos faltantes). Las variables categóricas también muestran cobertura alta, lo que permite un análisis estadístico sin imputación de datos.

8 Uso de la Librería `analizador`

8.1 Descripción

Como parte del proyecto, el equipo desarrolló la librería `analizador` — un paquete Python modular para análisis estadístico exploratorio de datasets CSV y Excel. La librería está disponible públicamente en:

https://github.com/Jserpa02/CD_pythonLibrary

8.2 Arquitectura

La librería implementa el principio de **separación de responsabilidades**, con cada módulo encargado de una función específica:

Módulo	Responsabilidad
<code>core.py</code>	Función orquestadora <code>analizar()</code> — coordina todos los módulos
<code>calidad.py</code>	Datos faltantes y valores repetidos
<code>descriptiva.py</code>	Medidas de tendencia central, dispersión, posición y forma
<code>frecuencias.py</code>	Tablas de frecuencia para variables categóricas
<code>graficos.py</code>	Histogramas, KDE, boxplots y barras de frecuencia

8.3 Uso en este trabajo

Todo el análisis estadístico de este informe se realizó mediante una única llamada:

```
from analizador import analizar

resultado = analizar(df)
```

Esta función devuelve un diccionario estructurado con cuatro claves principales:

```
resultado["calidad"]      # datos faltantes, valores repetidos
resultado["descriptiva"]  # mdtc, mdd, mdl, mdf
resultado["frecuencias"]  # tabla por cada variable categórica
resultado["graficos"]     # histogramas, kde, boxplots, barras
```

8.4 Decisiones de diseño relevantes

- **Sin dependencias estadísticas externas:** todas las fórmulas (cuartiles por interpolación lineal, KDE con ancho de banda de Silverman, varianza muestral con corrección de Bessel) están implementadas manualmente en Python puro usando `numpy`, sin depender de `scipy` ni de funciones estadísticas de `pandas`.
- **Funciones puras:** cada función recibe un `DataFrame` y devuelve un `DataFrame` o una figura `matplotlib.Figure`, sin efectos secundarios ni variables globales.

- **Instalable vía pip:** cualquier persona puede instalar la librería con `pip install git+https://github.com/Jserpa02/CD_pythonLibrary`.

9 Referencias

9.1 Dataset

Departamento Nacional de Planeación. (2024). *Terridata — Sistema de Estadísticas Territoriales*. <https://terridata.dnp.gov.co/index-app.html#/descargas>

9.2 Estadística descriptiva

Walpole, R. E., Myers, R. H., & Myers, S. L. (2012). *Probability and Statistics for Engineers and Scientists* (9th ed.). Pearson.

Montgomery, D. C., & Runger, G. C. (2014). *Applied Statistics and Probability for Engineers* (6th ed.). Wiley.

Mendenhall, W., Beaver, R. J., & Beaver, B. M. (2013). *Introduction to Probability and Statistics* (14th ed.). Cengage Learning.

9.3 Fórmulas específicas

Media aritmética y varianza muestral (corrección de Bessel): Spiegel, M. R., & Stephens, L. J. (2008). *Estadística* (4th ed., pp. 77–89). McGraw-Hill.

Cuartiles por interpolación lineal: Hyndman, R. J., & Fan, Y. (1996). Sample quantiles in statistical packages. *The American Statistician*, 50(4), 361–365. <https://doi.org/10.2307/2684934>

Asimetría y curtosis: Joanes, D. N., & Gill, C. A. (1998). Comparing measures of sample skewness and kurtosis. *Journal of the Royal Statistical Society: Series D*, 47(1), 183–189.

Estimación de densidad kernel (ancho de banda de Silverman): Silverman, B. W. (1986). *Density Estimation for Statistics and Data Analysis* (pp. 45–48). Chapman & Hall.

9.4 Herramientas

McKinney, W. (2010). Data Structures for Statistical Computing in Python. *Proceedings of the 9th Python in Science Conference*, 56–61.

Harris, C. R., et al. (2020). Array programming with NumPy. *Nature*, 585, 357–362. <https://doi.org/10.1038/s41586-020-2649-2>

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90–95.

Allaire, J. J., et al. (2024). *Quarto* (Version 1.4). <https://quarto.org>